

Instituto Tecnológico y de Estudios Superiores de Monterrey

Desarrollo de aplicaciones avanzadas de ciencias computacionales Gpo 505

Elda Guadalupe Quiroga González

Babyduck Entrega #0

Gabriel Eduardo Diaz Roa A00833574

22 de abril del 2025

1. Expresiones Regulares

Elemento léxico	Token	Expresión Regular
id	ID	[a-zA-Z_][a-zA-Z0-9_]*
Números Enteros	INT	[0-9]+
Números Flotantes	FLOAT	[0-9]+\.[0-9]+
Strings	STRING	\".*?\"
+	SUM	\+
-	MINUS	\-
*	MULTI	*
/	DIV	\/
<	L_THAN	<
>	G_THAN	>
!=	N_EQUAL	!=
=	ASSIGN	=
;	SEMI_COL	;
:	COLON	:
,	COMMA	,
(	L_PAREN	(
)	R_PAREN	)
{	L_BRACE	{
}	R_BRACE	}
[	L_BRACKET	[
]	R_BRACKET	]
program	PROGRAM	program
main	MAIN	main
end	END	end
var	VAR	var
print	PRINT	print
if	IF	if
else	ELSE	else
while	WHILE	While
do	DO	do

2. Tokens

Palabras clave:

program, main, end, print, if, else, while, do, var

Identificadores y constantes:

id, int, float, string

Operadores:

Aritméticos: +, -, *, /

Relacionales: <, >, !=

Asignación: =

Símbolos y signos de puntuación

Semicolon ;, Colon :, Comma ,

Paréntesis: L_PAREN (, R_PAREN)

Llaves: L_BRACE {, R_BRACE }

Corchetes: L_BRACKET [, R_BRACKET]

3. Context Free Grammar

programa $\rightarrow$ 'program' ID ';' vars funcs 'main' body 'end'

vars $\rightarrow$ var_decl vars

vars $\rightarrow \epsilon$

var_decl $\rightarrow$ 'var' tipo ID mas_ids ';'

mas_ids $\rightarrow$ ';' ID mas_ids

mas_ids $\rightarrow \epsilon$

tipo $\rightarrow$ 'int'

tipo $\rightarrow$ 'float'

funcs $\rightarrow$ function funcs

funcs $\rightarrow \epsilon$

function $\rightarrow$ tipo ID '(' params_opt ')' ':' vars body ';'

params_opt $\rightarrow$ params

params_opt $\rightarrow \epsilon$

params $\rightarrow$ tipo ID mas_params

mas_params $\rightarrow$ ',' tipo ID mas_params

mas_params $\rightarrow \epsilon$

body $\rightarrow$ '{' statements '}'

statements $\rightarrow$ statement statements

statements $\rightarrow \epsilon$

statement $\rightarrow$ assign ';'

statement $\rightarrow$ condition

statement $\rightarrow$ cycle

statement $\rightarrow$ print

assign $\rightarrow$ ID '=' expression

print $\rightarrow$ 'print' '(' expression mas_expresiones ')' ';'

mas_expresiones $\rightarrow$ ',' expression mas_expresiones

mas_expresiones $\rightarrow \epsilon$

condition $\rightarrow$ 'if' '(' expression ')' body else_opt

else_opt $\rightarrow$ 'else' body

else_opt $\rightarrow \epsilon$

cycle $\rightarrow$ 'while' '(' expression ')' 'do' body

expression $\rightarrow$ exp expression_opcional

expression_opcional $\rightarrow$ relop exp

expression_opcional $\rightarrow \epsilon$

relop $\rightarrow$ '=='

relop $\rightarrow$ '!='

relop $\rightarrow$ '<'

relop $\rightarrow$ '<='

relop $\rightarrow$ '>'

relop $\rightarrow$ '>='

exp $\rightarrow$ termino exp_suma

exp_suma $\rightarrow$ '+' termino exp_suma
exp_suma $\rightarrow$ '-' termino exp_suma
exp_suma $\rightarrow \epsilon$

termino $\rightarrow$ factor exp_mult

exp_mult $\rightarrow$ '*' factor exp_mult
exp_mult $\rightarrow$ '/' factor exp_mult
exp_mult $\rightarrow \epsilon$

factor $\rightarrow$ '(' expresion ')'
factor $\rightarrow$ CTE_INT
factor $\rightarrow$ CTE_FLOAT

factor $\rightarrow$ CTE_STRING
factor $\rightarrow$ ID
factor $\rightarrow$ f_call

f_call $\rightarrow$ ID '(' args_opt ')'

args_opt $\rightarrow$ args
args_opt $\rightarrow \epsilon$

args $\rightarrow$ expresion mas_args

mas_args $\rightarrow$ ',' expresion mas_args
mas_args $\rightarrow \epsilon$

Análisis de Herramientas de Generación de Compiladores

Herramientas Investigadas:

1. Flex & Bison
2. ANTLR
3. JavaCC

1. Flex & Bison

- Son herramientas clásicas del entorno Unix/Linux, herederas de Lex & Yacc.
- Flex genera analizadores léxicos (scanners) basados en autómatas finitos deterministas (DFA).
- Bison genera analizadores sintácticos (parsers) basados en técnicas LALR(1).
- Están diseñadas para funcionar en lenguaje C, lo cual puede dificultar su integración con otros lenguajes modernos como Java.
- Utilizan la línea de comandos como interfaz principal.
- Son muy estables y ampliamente usadas en sistemas de tipo UNIX.
- Licencia: GPL.

2. ANTLR (Another Tool for Language Recognition)

- Herramienta moderna escrita en Java.
- Permite generar analizadores léxicos y sintácticos para múltiples lenguajes de destino como Java, Python, C#, JavaScript y Go.
- Combina la definición de lexer y parser en un solo archivo .g4, facilitando la organización de proyectos.
- Utiliza técnicas de análisis LL(*) predictivo, permitiendo gramáticas más naturales sin necesidad de eliminar recursión izquierda.
- Genera automáticamente componentes adicionales como listeners y visitors para recorrer árboles de sintaxis.
- Ampliamente utilizada en la industria y en el ámbito académico para diseñar lenguajes, interpretes y compiladores.
- Licencia: BSD.

3. JavaCC (Java Compiler Compiler)

- Generador de analizadores léxicos y sintácticos escrito completamente en Java.
- Produce código Java puro sin dependencias externas en tiempo de ejecución.
- Utiliza técnicas de análisis LL(k) recursivo descendente.
- Es más sencillo de integrar en proyectos Java pequeños o medianos que no requieran árboles de sintaxis complejos.

- Comparado con ANTLR, su popularidad ha disminuido, aunque sigue siendo útil para ciertos tipos de proyectos.
- Licencia: BSD.

Conclusión del análisis

ANTLR resulta la mejor opción para el desarrollo de Baby_Duck, debido a su perfecta integración con Java, su robustez, su facilidad de uso y su documentación actualizada.

Definición de la Gramática de BabyDuck

Componente léxico	Token	Expresión regular
Identificador	ID	[a-zA-Z_][a-zA-Z_0-9]*
Constante entera	CTE_INT	[0-9]+
Constante flotante	CTE_FLOAT	[0-9]+ '.' [0-9]+
Cadena de texto	CTE_STRING	"" (~["\\"])* ""
Palabras clave	KEYWORDS	program, main, end, var, int, float, void, print, if, else, while, do
Operadores	OPERATORS	+, -, *, /, ==, !=, <, <=, >, >=
Delimitadores	SYMBOLS	;;, :, ,, (,), {, }, [,]

```
badito — -zsh — 39x42

PROGRAM      : 'program' ;
MAIN         : 'main' ;
END          : 'end' ;
VAR          : 'var' ;
INT          : 'int' ;
FLOAT        : 'float' ;
VOID         : 'void' ;
PRINT        : 'print' ;
IF           : 'if' ;
ELSE         : 'else' ;
WHILE        : 'while' ;
DO           : 'do' ;

PLUS         : '+' ;
MINUS        : '-' ;
MULT         : '*' ;
DIV          : '/' ;
ASSIGN       : '=' ;
EQ           : '==' ;
NEQ          : '!=' ;
LT           : '<' ;
LEQ          : '<=' ;
GT           : '>' ;
GEQ          : '>=' ;


SEMICOLON    : ';' ;
COLON        : ':' ;
COMMA        : ',' ;
LPAREN       : '(' ;
RPAREN       : ')' ;
LBRACE       : '{' ;
RBRACE       : '}' ;
LBRACKET     : '[' ;
RBRACKET     : ']' ;

ID           : [a-zA-Z_][a-zA-Z_0-9]* ;
CTE_INT      : [0-9]+ ;
CTE_FLOAT    : [0-9]+ '.' [0-9]+ ;
CTE_STRING   : '"' (~["\\])* '"' ;

WS           : [ \t\r\n]+ -> skip ;
LINE_COMMENT : '//' ~[\r\n]* -> skip ;
```

Cada regla gramatical sigue la estructura:

- Nombre de la regla
- Secuencia de tokens y subreglas
- Uso de repeticiones (*), opciones (?) y agrupaciones



```
programa : PROGRAM ID SEMICOLON vars funcs MAIN body END ;
vars : var_decl* ;
var_decl : VAR tipo ID (COMMA ID)* SEMICOLON ;
tipo : INT
      | FLOAT ;
funcs : function* ;
function : tipo ID LPAREN parametros? RPAREN COLON vars body SEMICOLON ;
parametros : tipo ID (COMMA tipo ID)* ;
body : LBRACE statements RBRACE ;
statements : statement* ;
statement : assign SEMICOLON
           | condition
           | cycle
           | print
           | f_call SEMICOLON ;
assign : ID ASSIGN expression ;
print : PRINT LPAREN expression (COMMA expression)* RPAREN SEMICOLON ;
condition : IF LPAREN expression RPAREN body (ELSE body)? ;
cycle : WHILE LPAREN expression RPAREN DO body ;
expression : exp (relop exp)? ;
relop : EQ
       | NEQ
       | LT
       | LEQ
       | GT
       | GEQ ;
exp : termino ((PLUS | MINUS) termino)* ;
termino : factor ((MULT | DIV) factor)* ;
factor : LPAREN expression RPAREN
        | CTE_INT
        | CTE_FLOAT
        | CTE_STRING
        | ID
        | f_call ;
f_call : ID LPAREN (expression (COMMA expression))* RPAREN ;
```


Organización de los Formatos

- Las expresiones regulares para el léxico fueron definidas en la sección de Lexer Rules del archivo .g4.
- Las reglas gramaticales fueron estructuradas en la sección de Parser Rules del mismo archivo.
- Se utilizó una combinación de la notación BNF y EBNF simplificada (propia de ANTLR), que permite expresar repeticiones, opcionales y alternativas de manera compacta.

Caso	Descripción	Entrada de prueba	Resultado
TC1	Programa mínimo válido	<pre>program hola; main { } end</pre>	Aceptado
TC2	Declaración de variables múltiples	<pre>program varTest; var int x, y, z; main { x = 1; y = 2; z = x + y; print(z); } end</pre>	Aceptado
TC3	Función sin parámetros	<pre>program funcSinParams; int suma() : var int a; { a = 1; print(a); }; main { print(1); } end</pre>	Aceptado
TC4	Función con parámetros	<pre>program funcParams; int mult(int x, float y) : var float res; { res = x * y; print(res); }; main { print(2); } end</pre>	Aceptado

TC5	Uso de while	<pre> program ciclo; var int i; main { i = 3; while (i > 0) do { print(i); i = i - 1; } } end </pre>	Aceptado
TC6	Condicional if-else	<pre> program decision; var int a; main { a = 5; if (a < 10) { print("Menor que 10"); } else { print("Mayor o igual que 10"); } } end </pre>	Aceptado
TC7	Error léxico	<pre> program 123Invalid; main { } end </pre>	Error (identificador inválido 123Invalid)
TC8	Error sintáctico (falta ; en asignación)	<pre> program errorSintaxis; var int x; main { x = 10 print(x); } end </pre>	Error (falta punto y coma después de x = 10)
TC9	Llamada a función	<pre> program llamado; int cuadrado(int x) : var int r; { r = x * x; print(r); }; main { cuadrado(5); } end </pre>	Aceptado

TC10	Expresión compuesta	<pre> program expr; var float resultado; main { resultado = (3 + 5) * 2.5; print(resultado); } end </pre>	Aceptado
-------------	------------------------	---	----------

```

badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc1.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc2.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc3.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc4.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc5.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc6.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc7.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc8.bd
line 1:8 extraneous input '123' expecting ID
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc9.bd
badito@Gabriels-MacBook-Pro Babyduck % java -cp ".:antlr-4.13.2-complete.jar" Main tests/tc10.bd
badito@Gabriels-MacBook-Pro Babyduck %

```

Tabla de Consideraciones Semánticas

Aritmetica

Operando Izquierdo	Operando Derecho	+	-	*	/
int	int	int	int	int	int
int	float	float	float	float	float
float	int	float	float	float	float
float	float	float	float	float	float

Relaciones

Operando Izquierdo	Operando Derecho	==	!=	<	<=	>	>=
int	int	bool	bool	bool	bool	bool	bool
int	float	error	error	error	error	error	error
float	int	error	error	error	error	error	error
float	float	bool	bool	bool	bool	bool	bool

Directorio de Funciones

El Directorio de Funciones es una estructura de datos diseñada para registrar toda la información relevante de cada función declarada en el programa BabyDuck. Está implementado mediante un diccionario (HashMap) cuya clave es el nombre de la función, y cuyo valor es una instancia de una clase FunctionInfo. Esta clase almacena el tipo de retorno de la función, la lista de tipos de parámetros y una tabla de variables locales asociada a esa función. Además, el directorio mantiene un campo llamado `currentFunction` que indica cuál es la función activa durante el análisis, lo cual permite asignar variables o parámetros en el contexto correcto.

Esta estructura permite realizar validaciones importantes como:

- Evitar la declaración duplicada de funciones.
- Registrar y acceder al tipo de retorno de cada función.
- Validar la existencia y la cantidad de parámetros durante llamadas a funciones.
- Asociar una tabla de variables para mantener el alcance léxico correctamente definido.

El Directorio de Funciones también contempla una función especial llamada "global" que representa el contexto del programa principal fuera de cualquier función. Las variables globales se almacenan en esta entrada para ser accesibles desde cualquier parte del programa.

Tabla de Variables

La Tabla de Variables es una estructura auxiliar utilizada dentro de cada función del Directorio de Funciones. Está implementada también como un diccionario (HashMap), donde cada clave corresponde al nombre de una variable, y su valor es el tipo de dato asociado a dicha variable (int, float o string). Cada función contiene su propia instancia de esta tabla, lo que permite mantener un ámbito léxico separado entre funciones.

Durante el análisis semántico, cada vez que se declara una variable, se registra en la tabla correspondiente a la función activa. Esta estructura permite realizar validaciones clave como:

- Verificar que una variable no haya sido declarada más de una vez en el mismo ámbito.
- Consultar el tipo de una variable para validar asignaciones y expresiones.
- Distinguir entre variables locales y globales según el contexto actual.

La separación de variables por función permite un control riguroso del alcance y facilita la implementación de reglas semánticas relacionadas con la visibilidad y el uso correcto de identificadores en el lenguaje BabyDuck.

Puntos neurálgicos

1. Inicio del programa
 - Se crea el contexto "global" en el Directorio de Funciones.
 - No requiere validaciones en esta etapa.
2. Declaración de funciones
 - Se registra el nombre y tipo de retorno.
 - Se valida que la función no esté previamente declarada.
3. Registro de parámetros
 - Se agregan a la lista de parámetros y a la tabla de variables local.
 - Se valida que no haya nombres duplicados entre parámetros o con variables locales.
4. Declaración de variables
 - Se registran en la tabla de variables del contexto activo.
 - Se valida que no se repita el nombre dentro del mismo ámbito.
5. Asignaciones
 - Se verifica que la variable esté declarada antes de usarse.
 - Se puede extender para validar compatibilidad de tipos.
6. Uso de identificadores en expresiones
 - Se valida que todas las variables usadas estén declaradas.
 - Se puede obtener su tipo para verificar operaciones posteriores.
7. Evaluación de expresiones
 - Se determina el tipo resultante de operaciones.
 - Se puede aplicar un cubo semántico para validar operadores entre tipos.
8. Gestión del contexto
 - Se mantiene el valor de `currentFunction` para saber dónde insertar o buscar variables.
 - Asegura que cada declaración o referencia se haga en el ámbito correcto.